Formation Data Scientist Machine Learning
Projet 4 :

Identifier les causes d’attrition au sein d’une ESN

Faïza KHELLADI

Context

Taux de démission élevé

Identification des causes de départs

Sources de données

- Extrait SIRH
- Évaluations annuelles
- Sondage employés

Modèle de prédiction des départs des employés

Anticipation des risques de démission

Préservation des talents et réduction du coût du turnover

Sommaire

- Processus de prédiction des départs des employés
- Sources de données des employés
- Analyse descriptive liée aux données des employés
- Préparation des données
- Modélisation pour la prédiction des départs
  - Comparaison de différents modèles supervisés
  - Optimisation du modèle retenu
- Interprétation globale et locale de l’importance des features
- Conclusion et perspectives

Processus de prédiction des départs des employés

Identification des données pertinentes

- Analyse des données des employés
- Sélection des variables prédictives
- Sélection des variables cibles (l'employé a quitté l'entreprise)

Préparation des données

- Feature engineering
- Séparation des données en X et y
- Encodage des données catégorielles

Prédiction de la cible et réduction de coût du turnover

- Comparaison de différents modèles supervisés
- Optimisation du modèle retenu
- Identification des variables influentes et recommandation pour la RH

Source de données des employés

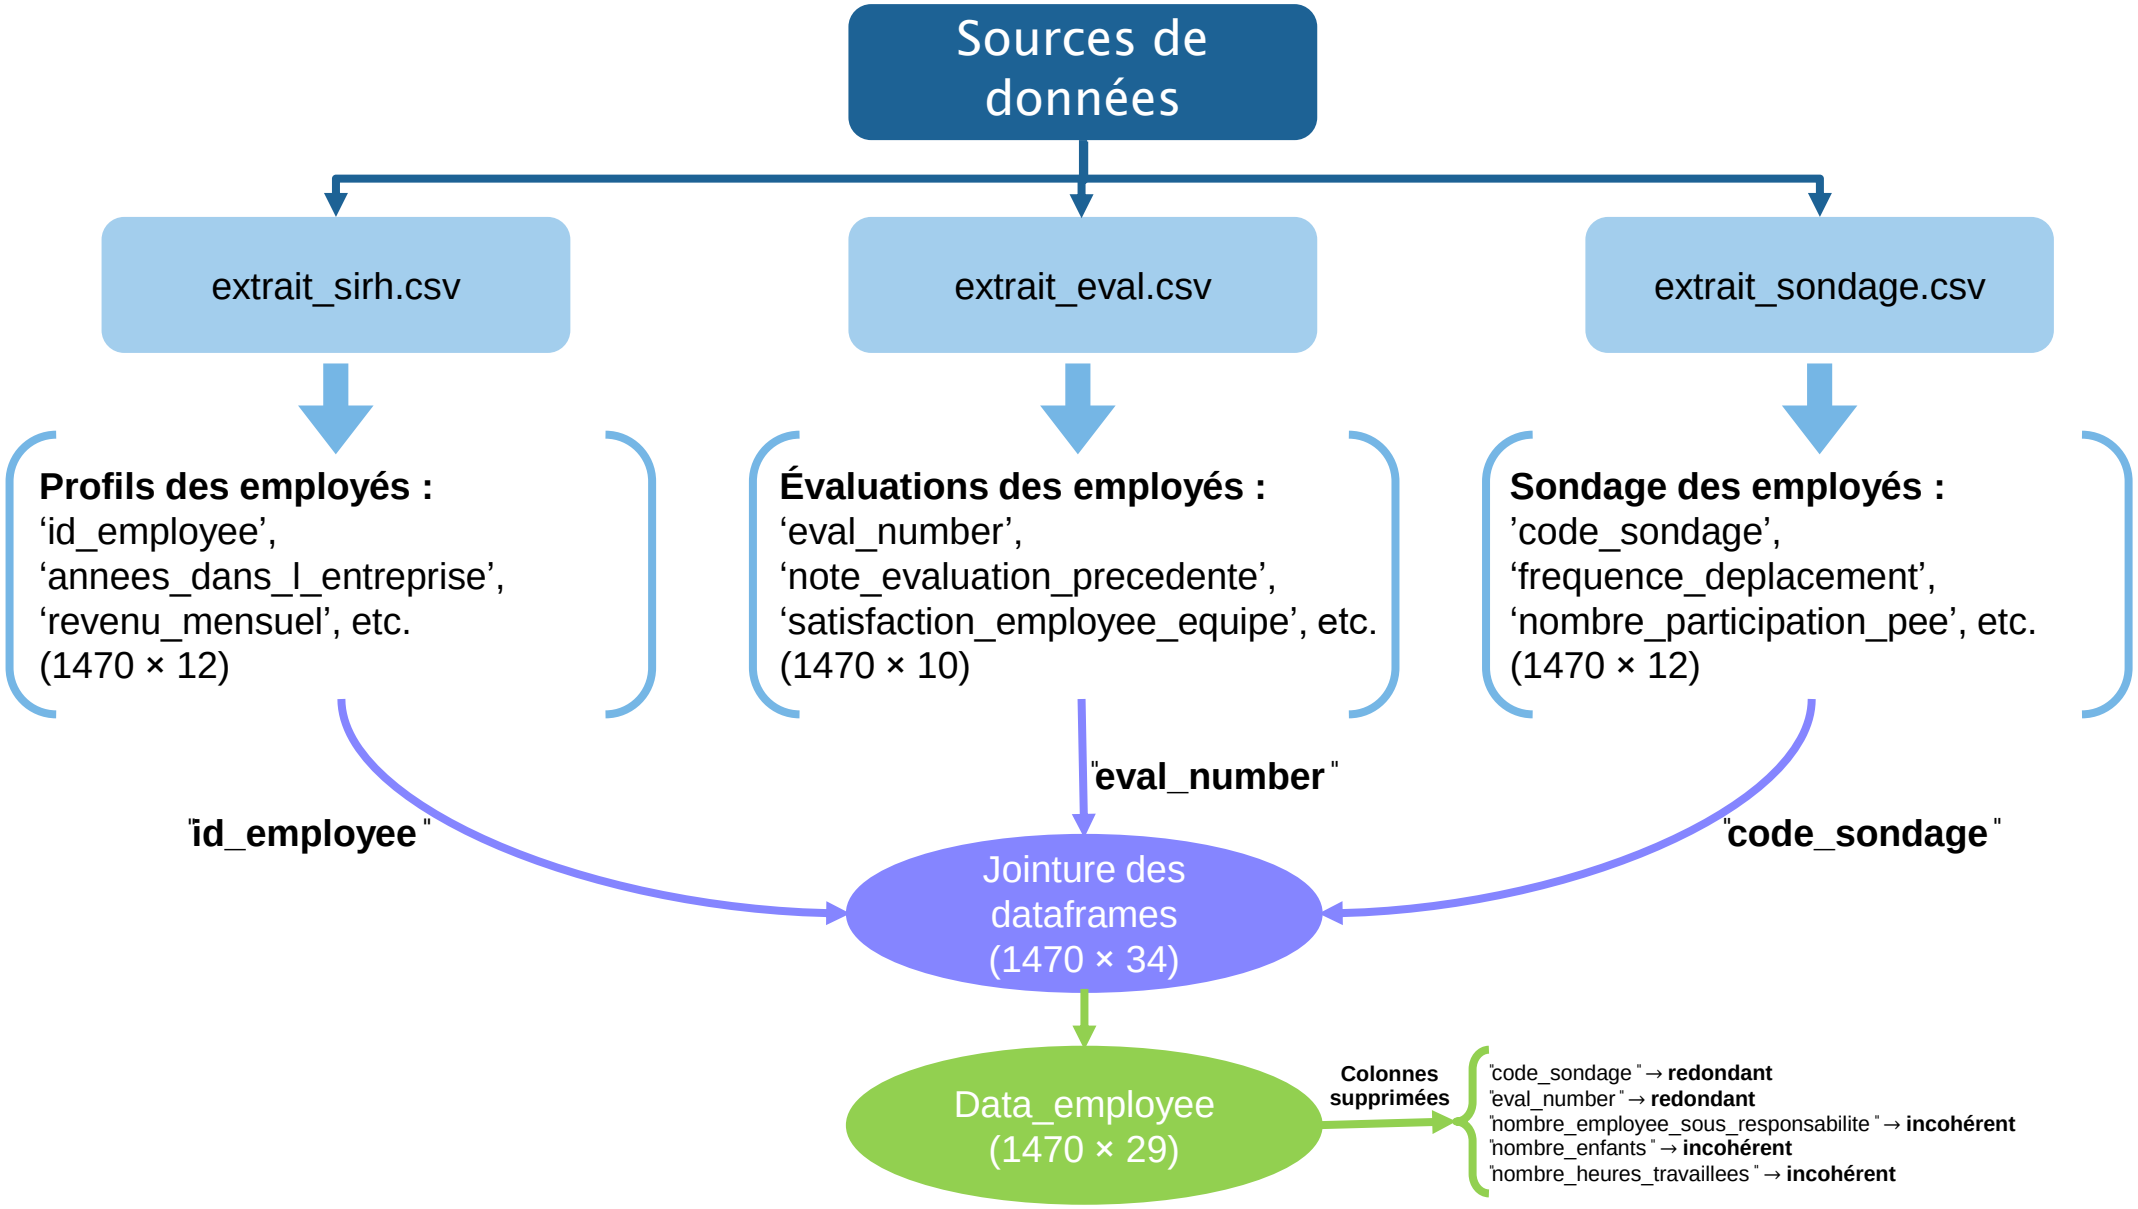

Analyse descriptive liée aux données des employés

Features numériques

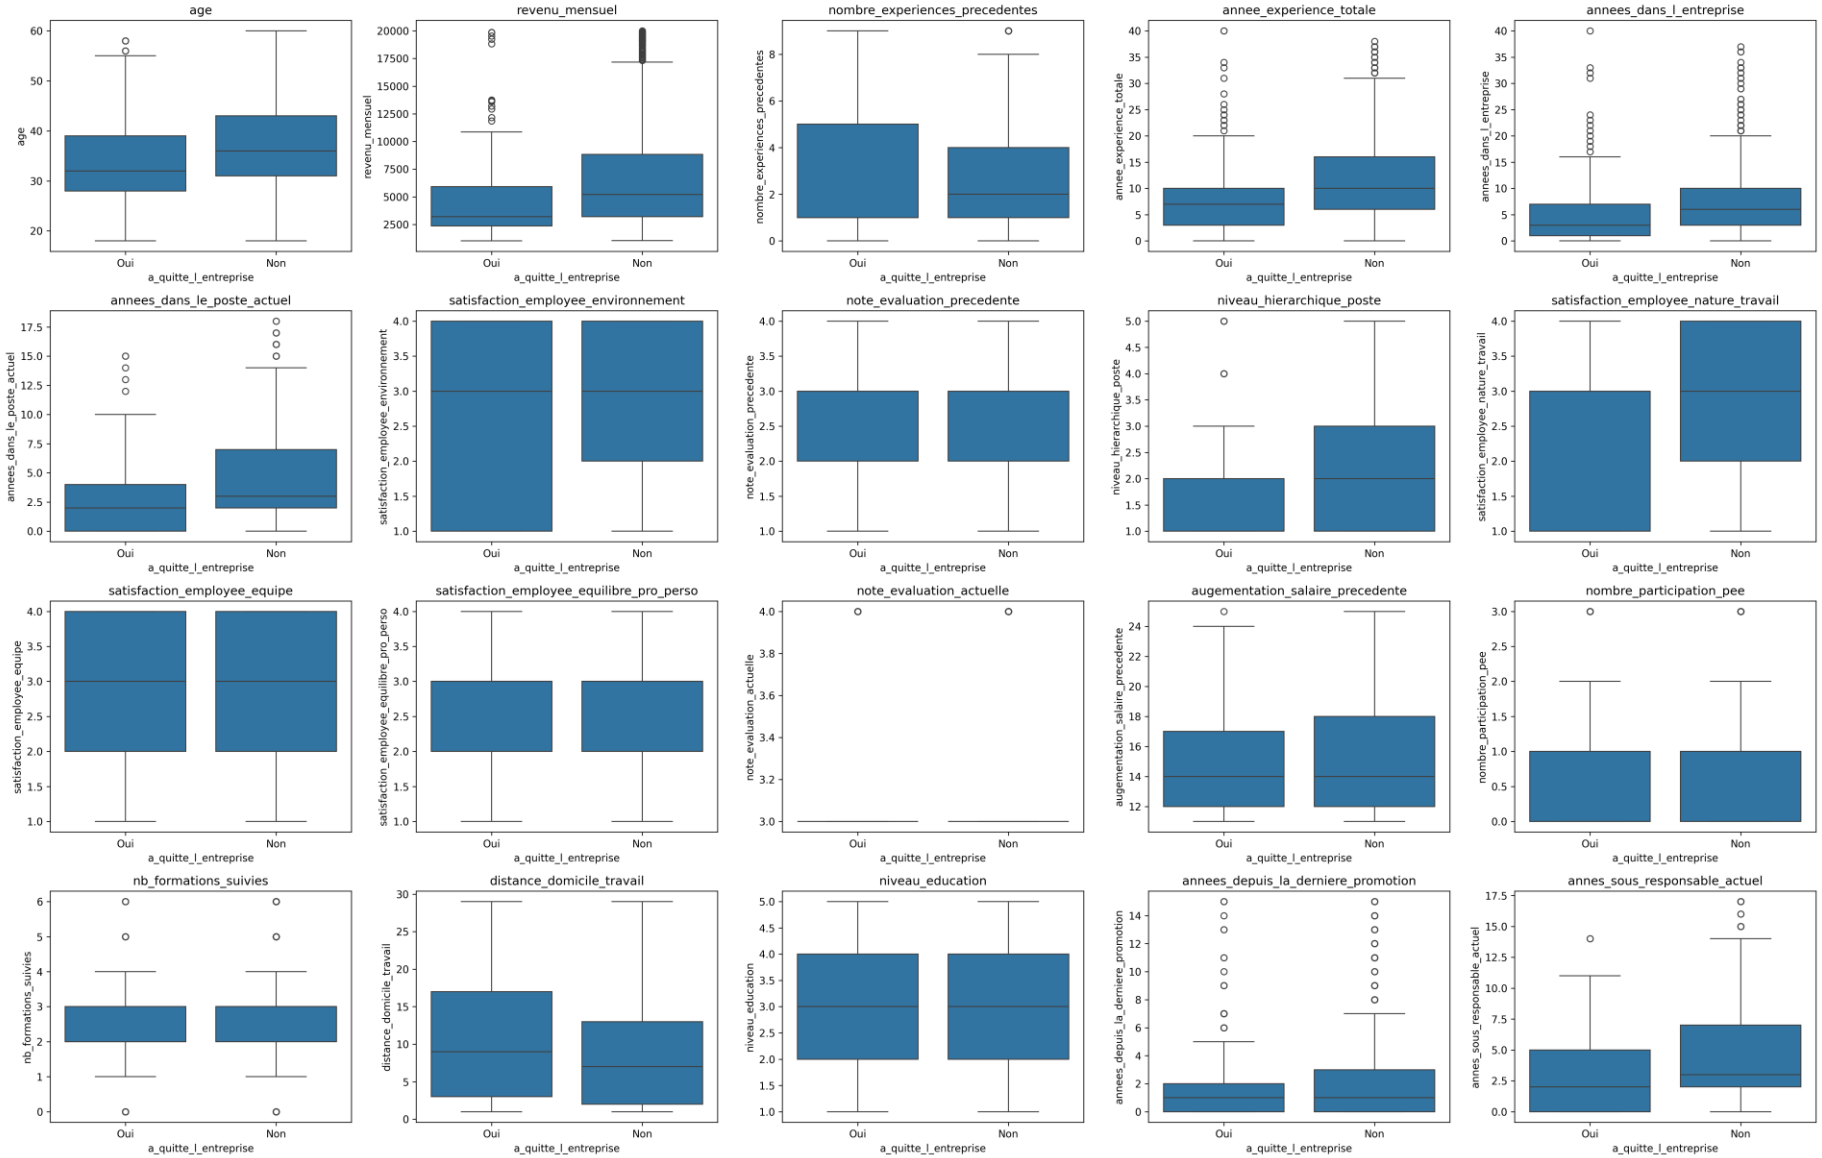

Analyse descriptive liée aux données des employés

Features catégorielles

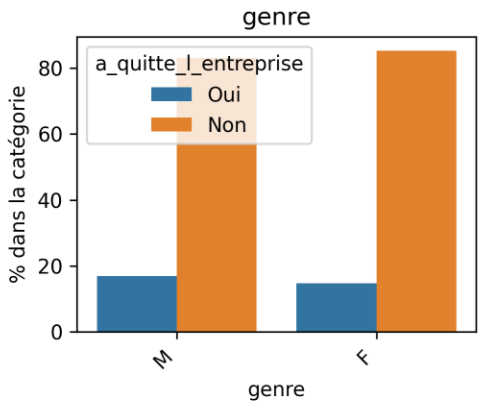

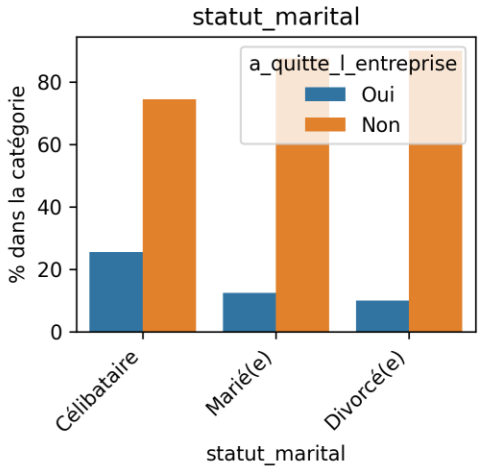

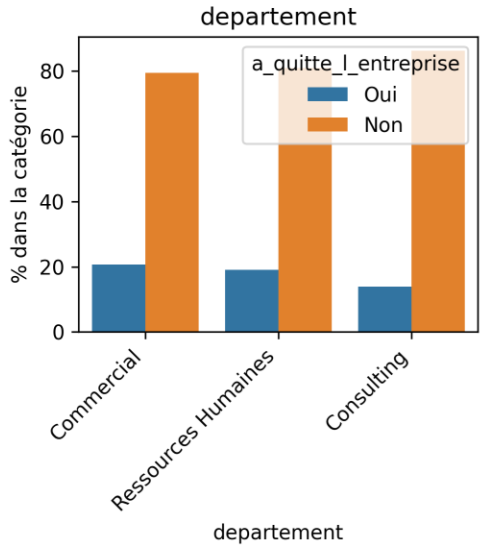

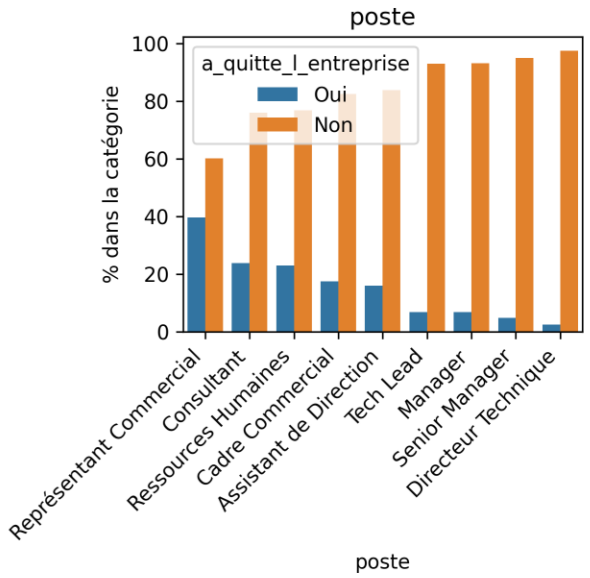

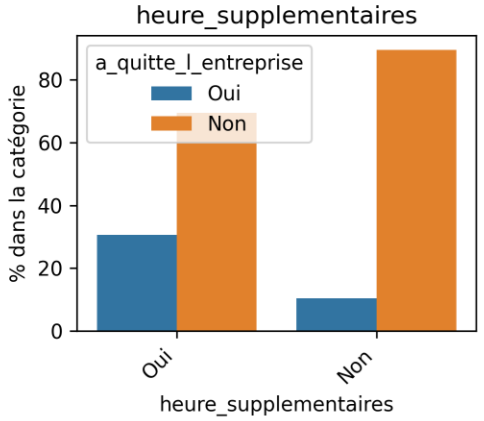

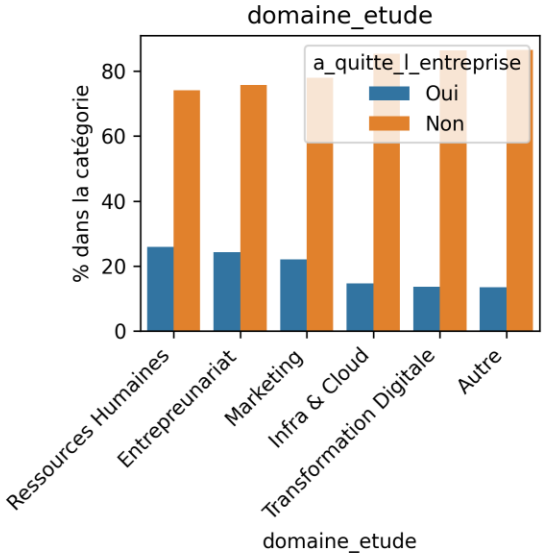

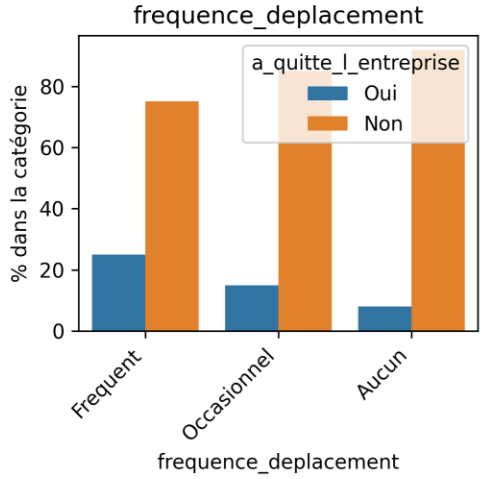

Préparation des données

Feature engineering

Création de la variable 1 :
Variation de la note d'évaluation

note_evaluation_variation = note_evaluation_actuelle - note_evaluation_precedente

Création de la variable 2 :
Moyenne des notes de satisfaction

satisfaction_moyenne = moyenne(colonnes commençant par 'satisfaction_')

Création de la variable 3 :
Vote de satisfaction

$$\text{satisfaction_vote} = \begin{cases} 0 \; si \; \text{satisfaction}_{\text{moyenne}} < 2{,}5 \\ 1 \; sinon \end{cases}$$

Moyenne de satisfaction

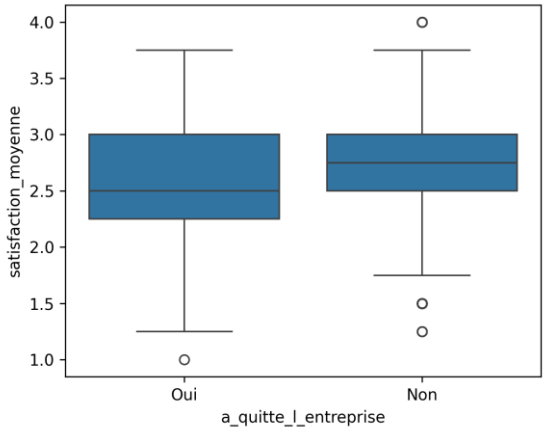

Vote de satisfaction

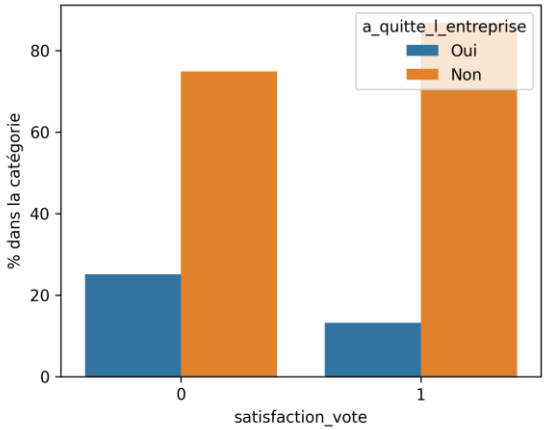

Préparation des données

Feature engineering

Création de la variable 4 :
Chute dans la satisfaction et l'évaluation

evaluation_satisfaction = (note_evaluation_variation > 0) & (satisfaction_vote =1)

Evaluation & satisfaction

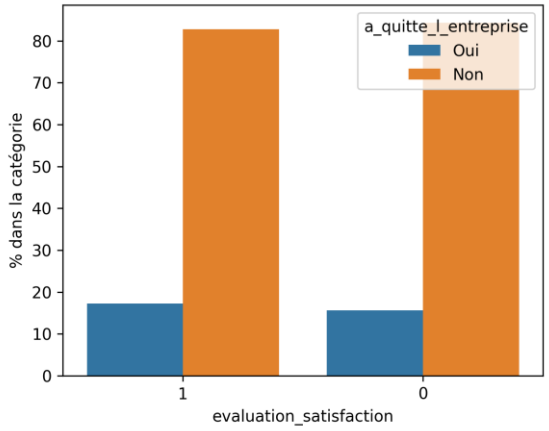

Création de la variable 5 :
Ratio entre la satisfaction et l'ancienneté dans l'entreprise

ratio_satisfaction_anciennete = satisfaction_moyenne/(annees_dans_l_entreprise+1)

satisfaction/ancienneté

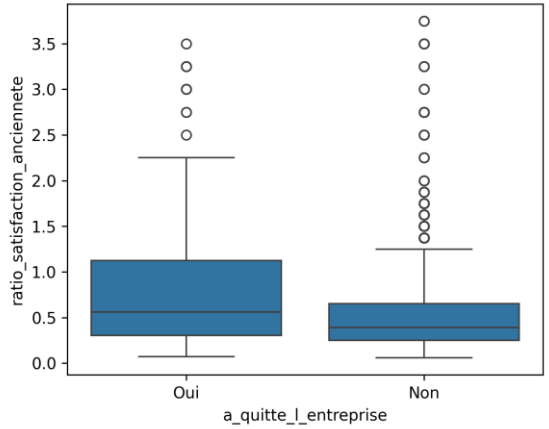

Préparation des données

Feature engineering

Création de la variable 6 :
Risque de burnout

risque_burnout = (satisfaction_vote = 0) & (heure_supplementaires = Oui)

Probabilité de démission selon le burnout

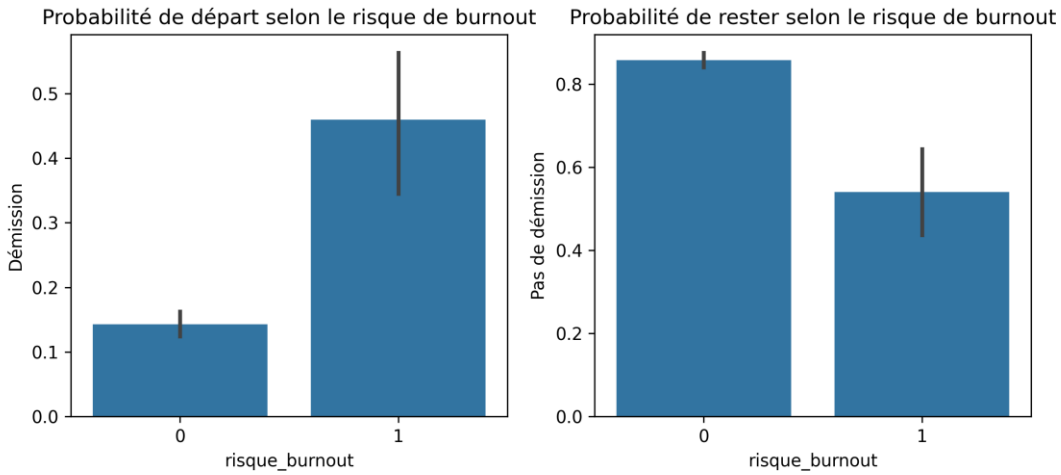

Création de la variable 7 :
Ratio entre revenue mensuel et salaire moyen par poste

salaire_moyen_poste = moyenne(revenu des employés ayant le même poste)
ratio_salaire_moyen_poste = revenu_mensuel / salaire_moyen_poste

Ratio salaire moy./poste

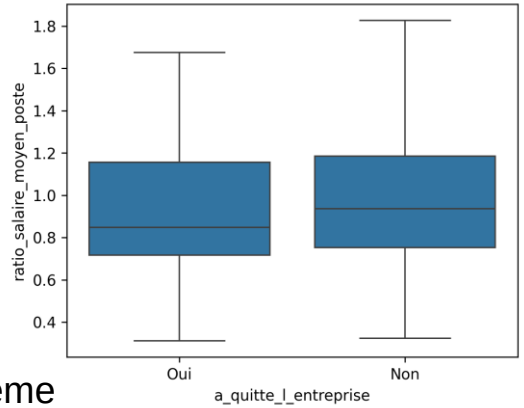

Ratio salaire moy./poste/dep.

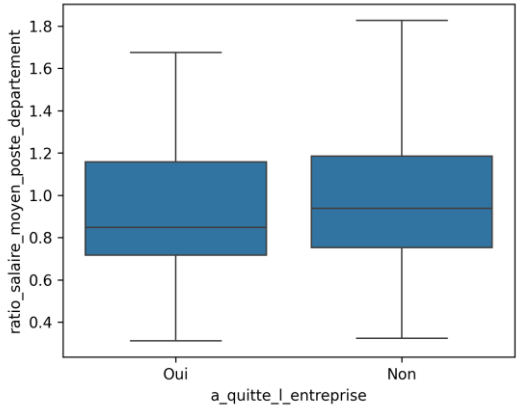

Création de la variable 8 :
ratio entre revenue mensuel et salaire moyen par poste par département

salaire_moyen_poste_departement = moyenne(revenu des employés ayant le même poste par département)
ratio_salaire_moyen_poste_departement = revenu_mensuel / salaire_moyen_poste

Préparation des données

Feature engineering

Création de la variable 9 :
Satisfaction VS ratio de salaire moyen par poste par departement

non_satisfait_sous_paye = (satisfaction_vote = 0)
& (ratio_salaire_moyen_poste_departement <1)

Non-satisfait / sous-payé

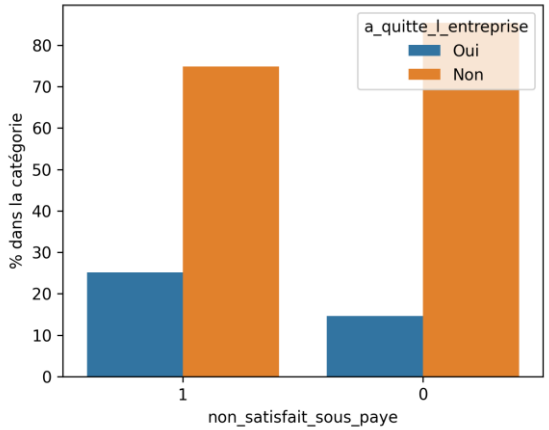

Création de la variable 10 :
Mobilité interne

mobilite_interne = annees_dans_l_entreprise - annees_dans_le_poste_actuel

Mobilité interne

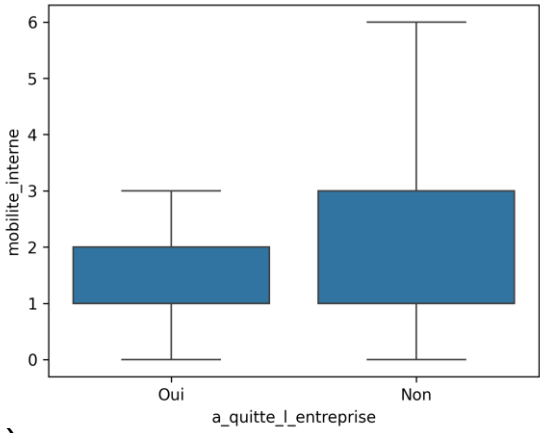

Ratio de stagnation

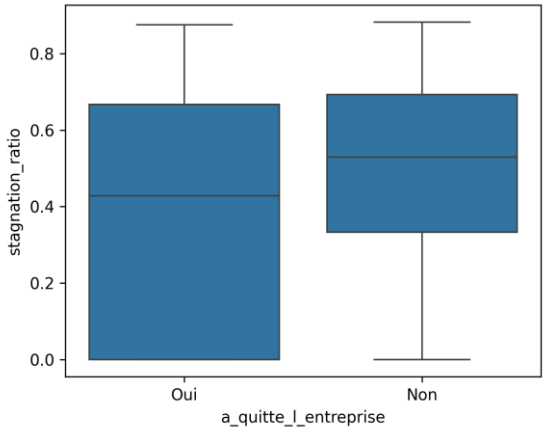

Création de la variable 11 :
Ratio de stagnation

stagnation_ratio = annees_dans_le_poste_actuel/(annees_dans_l_entreprise+1)

Préparation des données

Feature engineering

Matrice de corrélation

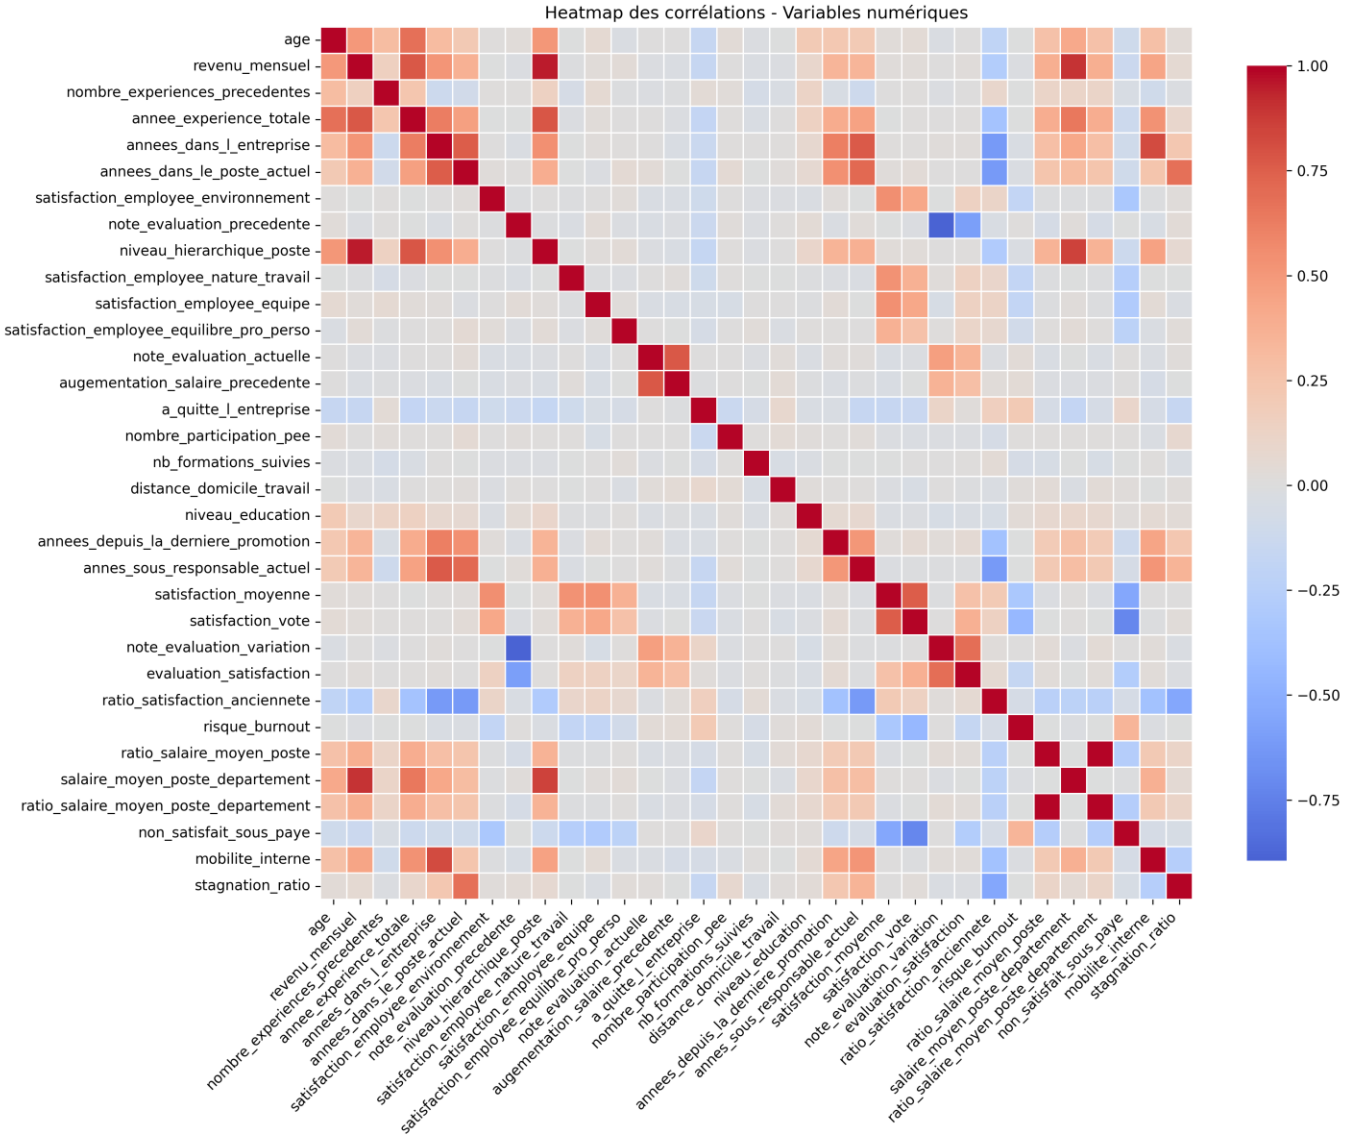

Préparation des données

Feature engineering

Matrice de corrélation > 0,7

Colonnes à supprimer

- niveau_hierarchique_poste
- annees_sous_responsable_actuel
- satisfaction_vote
- ratio_salaire_moyen_poste
- note_evaluation_actuelle

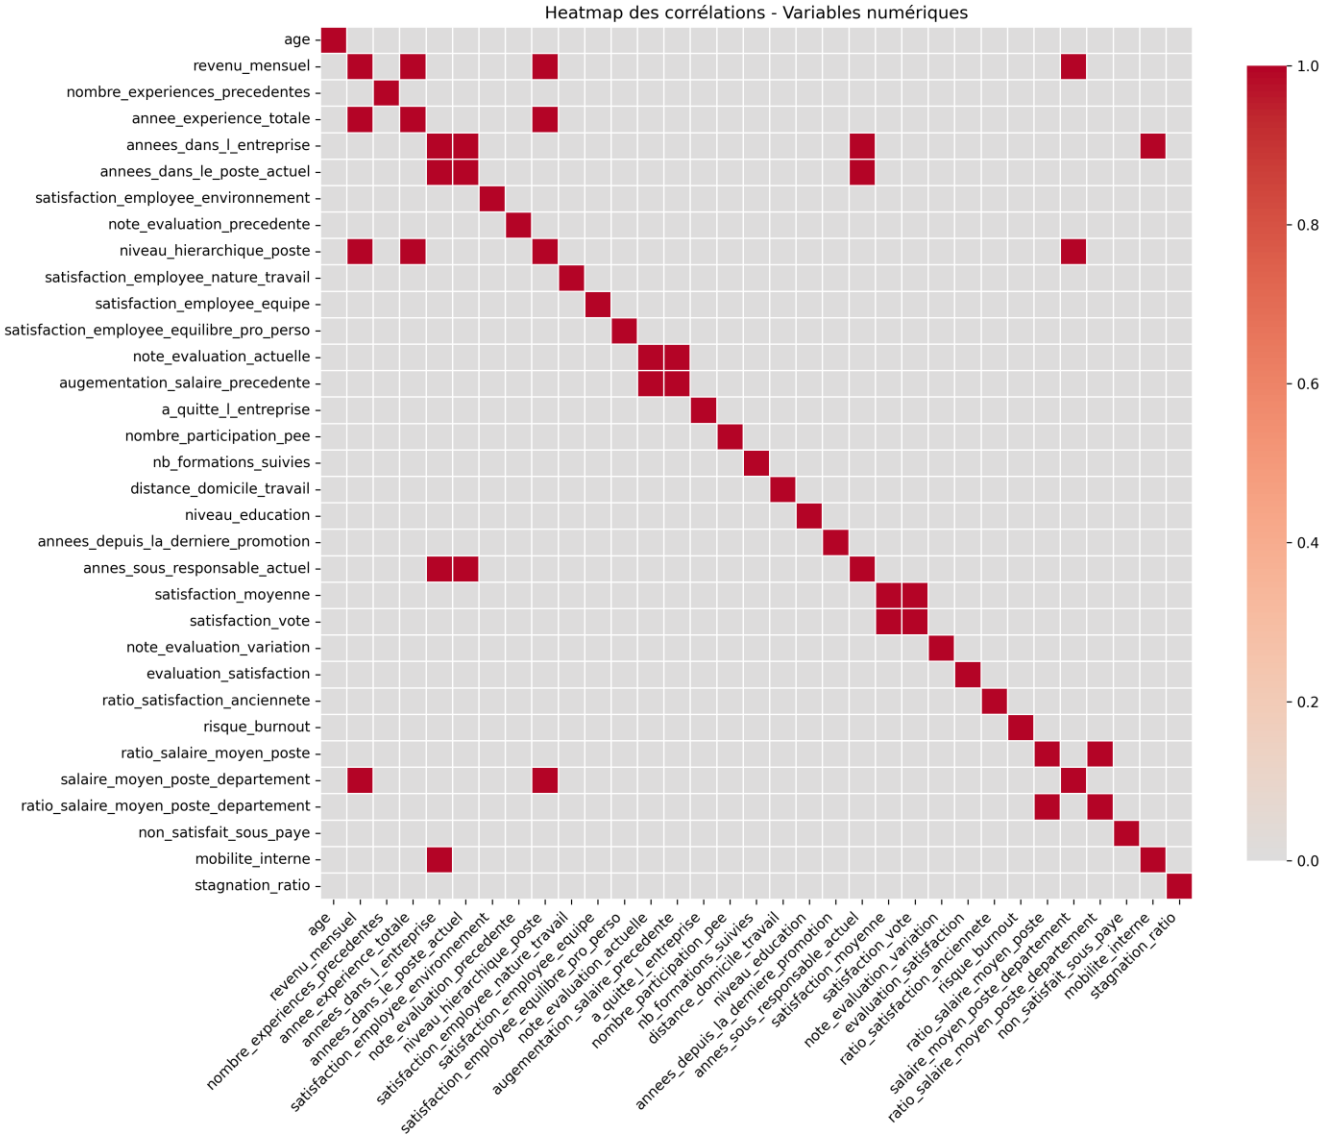

Préparation des données

Encodage des données

Variables catégorielles
X :

- statut_marital
- genre
- departement
- poste
- domaine_etude

1470 ×5

OneHotEncoder

- statut_marital_Célibataire
- statut_marital_Divorcé(e)
- statut_marital_Marié(e)

1470 ×3

- genre_F
- genre_M

1470 ×2

- departement_Commercial
- departement_Consulting
- departement_Ressources Humaines

1470 ×3

- poste_Assistant de direction
- poste_Cardre commercial
- ⋮

1470 ×9

- domaine_etude_Entreprenariat
- domaine_etude_Marketing
- ⋮

1470 ×6

- heures_supplementaires
- frequence_deplacement

Y :

- a_quitte_l_entreprise

1470 ×3

Mapping

heures_supplementaires
- Non : 0
- Oui : 1

1470 ×1

frequence_deplacement
- Aucun : 0
- Occasionnel : 1
- Frequent : 2

1470 ×1

a_quitte_l_entreprise
- Non : 0
- Oui : 1

1470 ×1

Variables numériques
+
Variables cat. Encodées
=
X
Variable cible = **y**

Modélisation pour la prédiction des départs

Comparaison de différents modèles supervisés : Dummy classifier

Classification report - train

	precision	recall	f1-score	support
0	0.83	1.00	0.91	978
1	0.00	0.00	0.00	198
accuracy			0.83	1176
macro avg	0.42	0.50	0.45	1176
weighted avg	0.69	0.83	0.76	1176

Classification report - test

	precision	recall	f1-score	support
0	0.87	1.00	0.93	255
1	0.00	0.00	0.00	39
accuracy			0.87	294
macro avg	0.43	0.50	0.46	294
weighted avg	0.75	0.87	0.81	294

Matrice de confusion

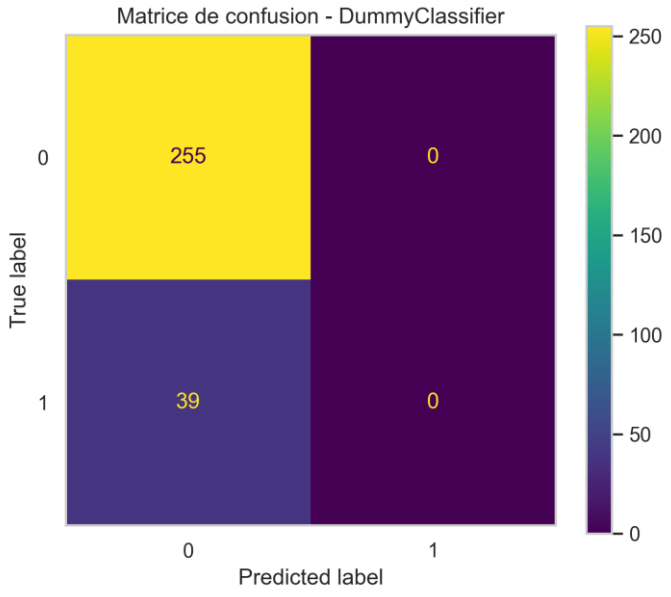

PR curve

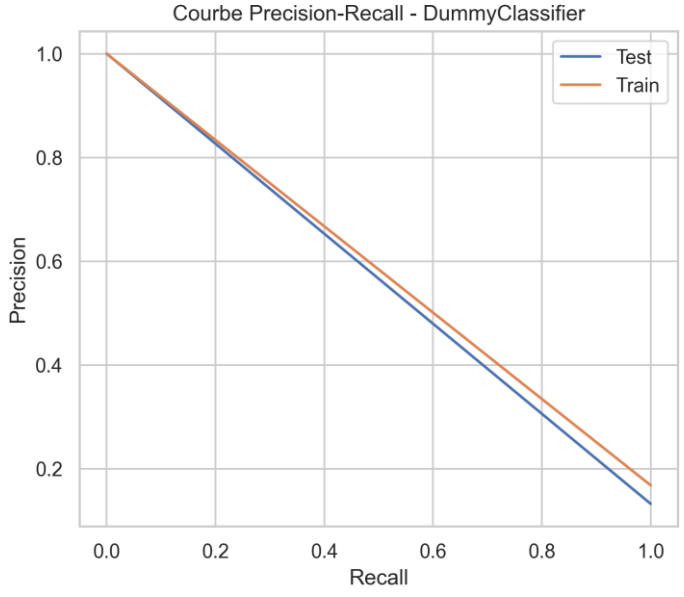

Dummy Classifier : modèle de référence pour comparer les performances des modèles ML.

Modélisation pour la prédiction des départs

Comparaison de différents modèles supervisés : Logistic regression

Classification report - train

	precision	recall	f1-score	support
0	0.91	0.98	0.94	978
1	0.82	0.49	0.62	198
accuracy			0.90	1176
macro avg	0.86	0.74	0.78	1176
weighted avg	0.89	0.90	0.89	1176

Classification report - test

	precision	recall	f1-score	support
0	0.91	0.96	0.94	255
1	0.62	0.38	0.48	39
accuracy			0.89	294
macro avg	0.77	0.67	0.71	294
weighted avg	0.87	0.89	0.88	294

Matrice de confusion

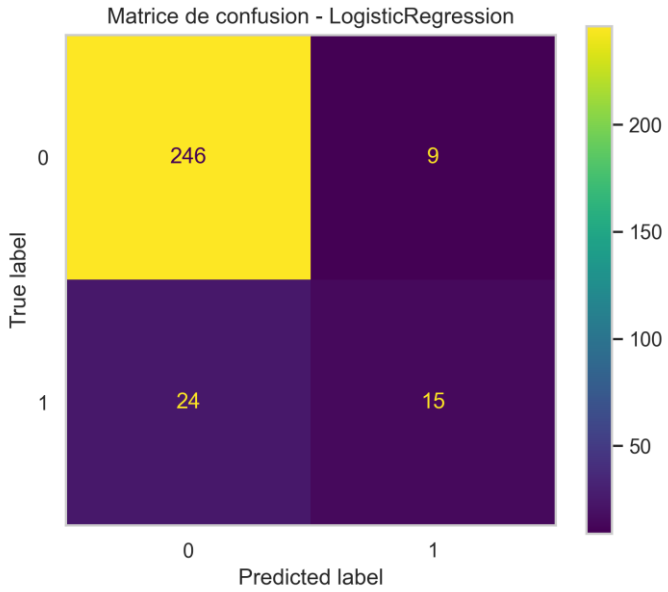

PR curve

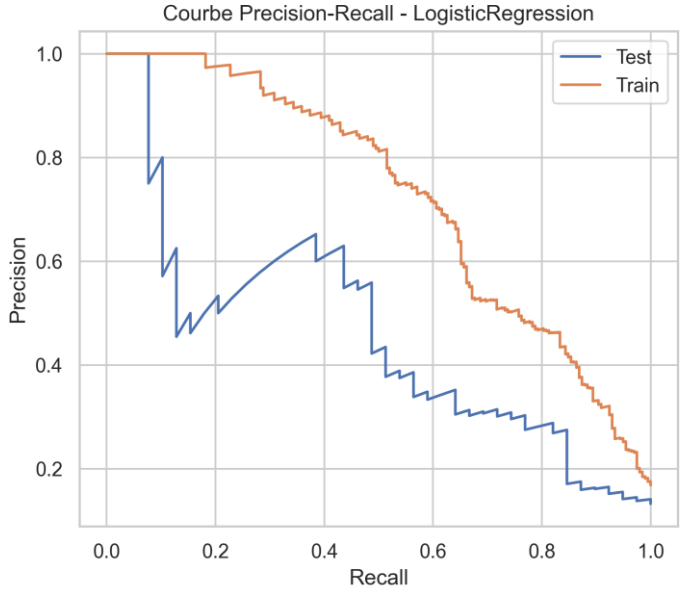

- Amélioration globale des performances par rapport au modèle de référence (dummy classifier).
- Détection partielle des départs, avec encore plusieurs faux négatifs

Modélisation pour la prédiction des départs

Comparaison de différents modèles supervisés : XGBoost (1/3)

Classification report - train

	precision	recall	f1-score	support
0	1.00	1.00	1.00	978
1	1.00	0.99	0.99	198
accuracy			1.00	1176
macro avg	1.00	0.99	1.00	1176
weighted avg	1.00	1.00	1.00	1176

Classification report - test

	precision	recall	f1-score	support
0	0.89	0.93	0.91	255
1	0.39	0.28	0.33	39
accuracy			0.85	294
macro avg	0.64	0.61	0.62	294
weighted avg	0.83	0.85	0.84	294

Matrice de confusion

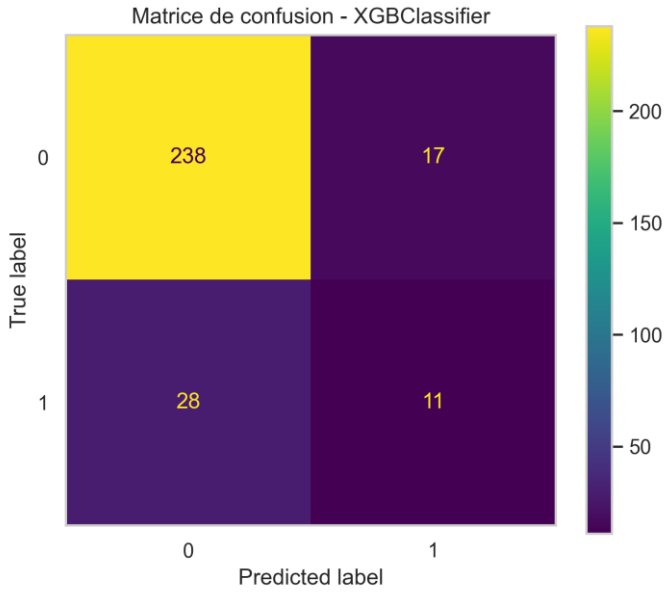

PR curve

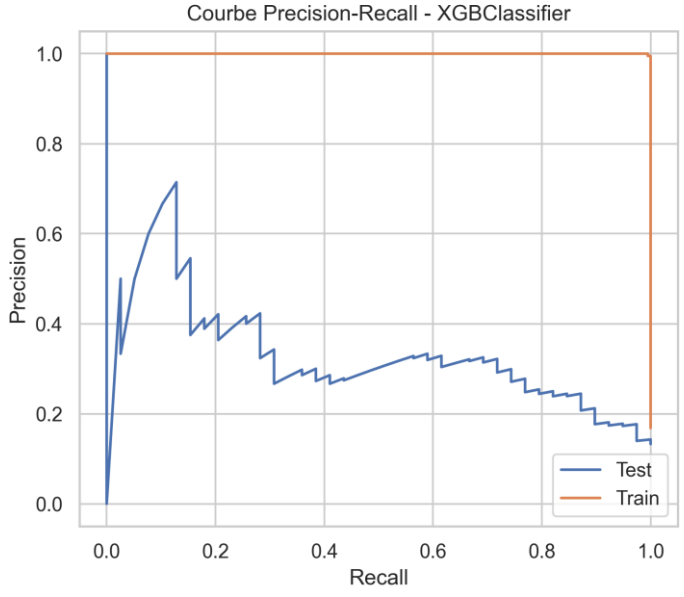

XGBoost optimisé :

- Performances quasi parfaites sur le train avec un grand écart train-test → surapprentissage
- Peu de départs détectés, plusieurs faux négatifs persistent.

Modélisation pour la prédiction des départs

Comparaison de différents modèles supervisés : XGBoost (2/3)

Classification report - train

	precision	recall	f1-score	support
0	0.98	0.51	0.67	986
1	0.27	0.96	0.43	190
accuracy			0.58	1176
macro avg	0.63	0.73	0.55	1176
weighted avg	0.87	0.58	0.63	1176

Classification report - test

	precision	recall	f1-score	support
0	0.95	0.48	0.64	247
1	0.24	0.87	0.38	47
accuracy			0.54	294
macro avg	0.60	0.68	0.51	294
weighted avg	0.84	0.54	0.59	294

Matrice de confusion

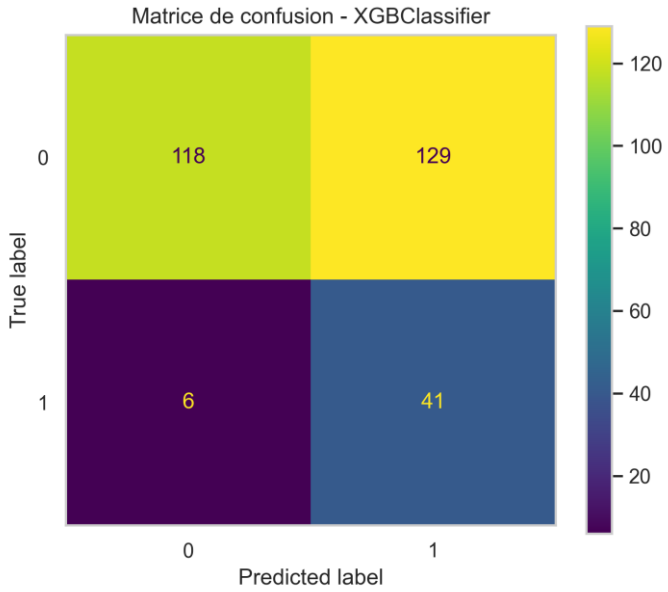

PR curve

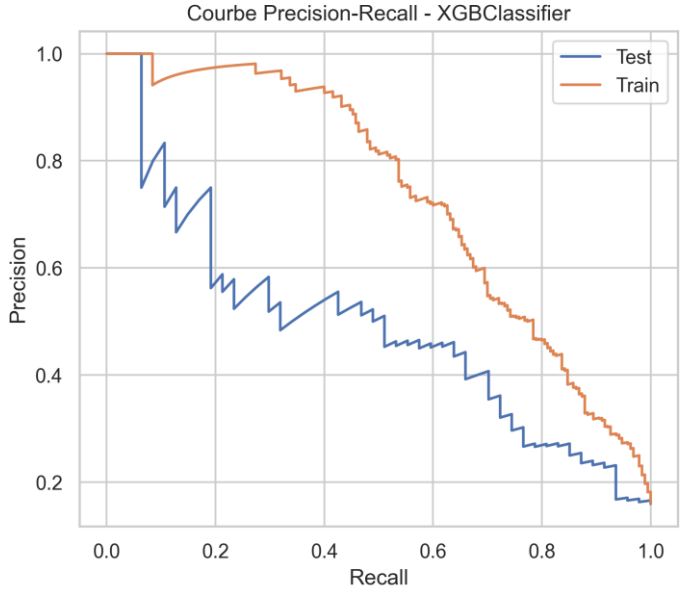

XGBoost optimisé avec stratification et équilibrage des classes :

- Amélioration du recall des départs grâce au rééquilibrage des classes.
- Meilleure détection des départs, mais augmentation des faux positifs.
- Le seuil par défaut (seuil = 0,5) limite la détection optimale des départs.

Modélisation pour la prédiction des départs

Comparaison de différents modèles supervisés : XGBoost (3/3)

Optimisation du seuil de détection

Calcul des probabilités de départ → Maximisation du score F2 → Meilleur seuil : 0,711 Meilleur score F2 : 0,613 → Amélioration de la détection des départs

Classification report - train

	precision	recall	f1-score	support
0	0.93	0.81	0.87	247
1	0.41	0.70	0.52	47
accuracy			0.79	294
macro avg	0.67	0.75	0.69	294
weighted avg	0.85	0.79	0.81	294

PR curve

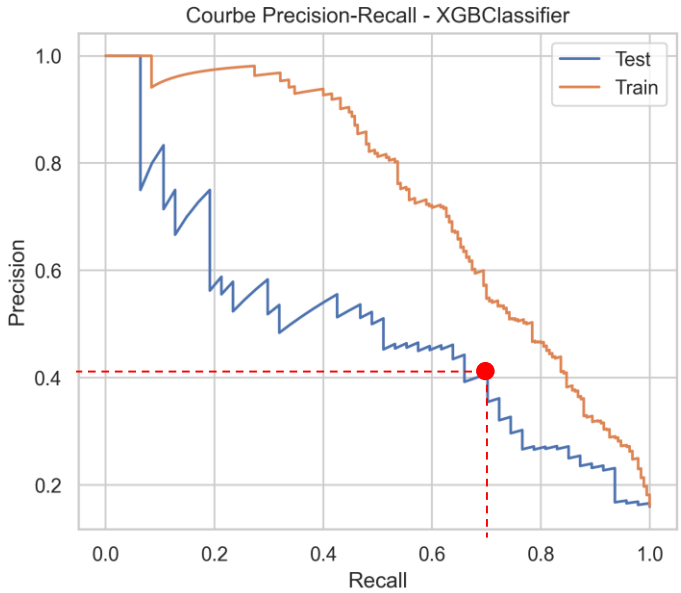

- Seuil optimal maximisant le score F2
- Optimisation du seuil pour améliorer la détection des départs.
- Meilleur compromis entre précision et rappel pour la classe départ

Modélisation pour la prédiction des départs

Interprétation globale de l’importance des features : feature_importances_

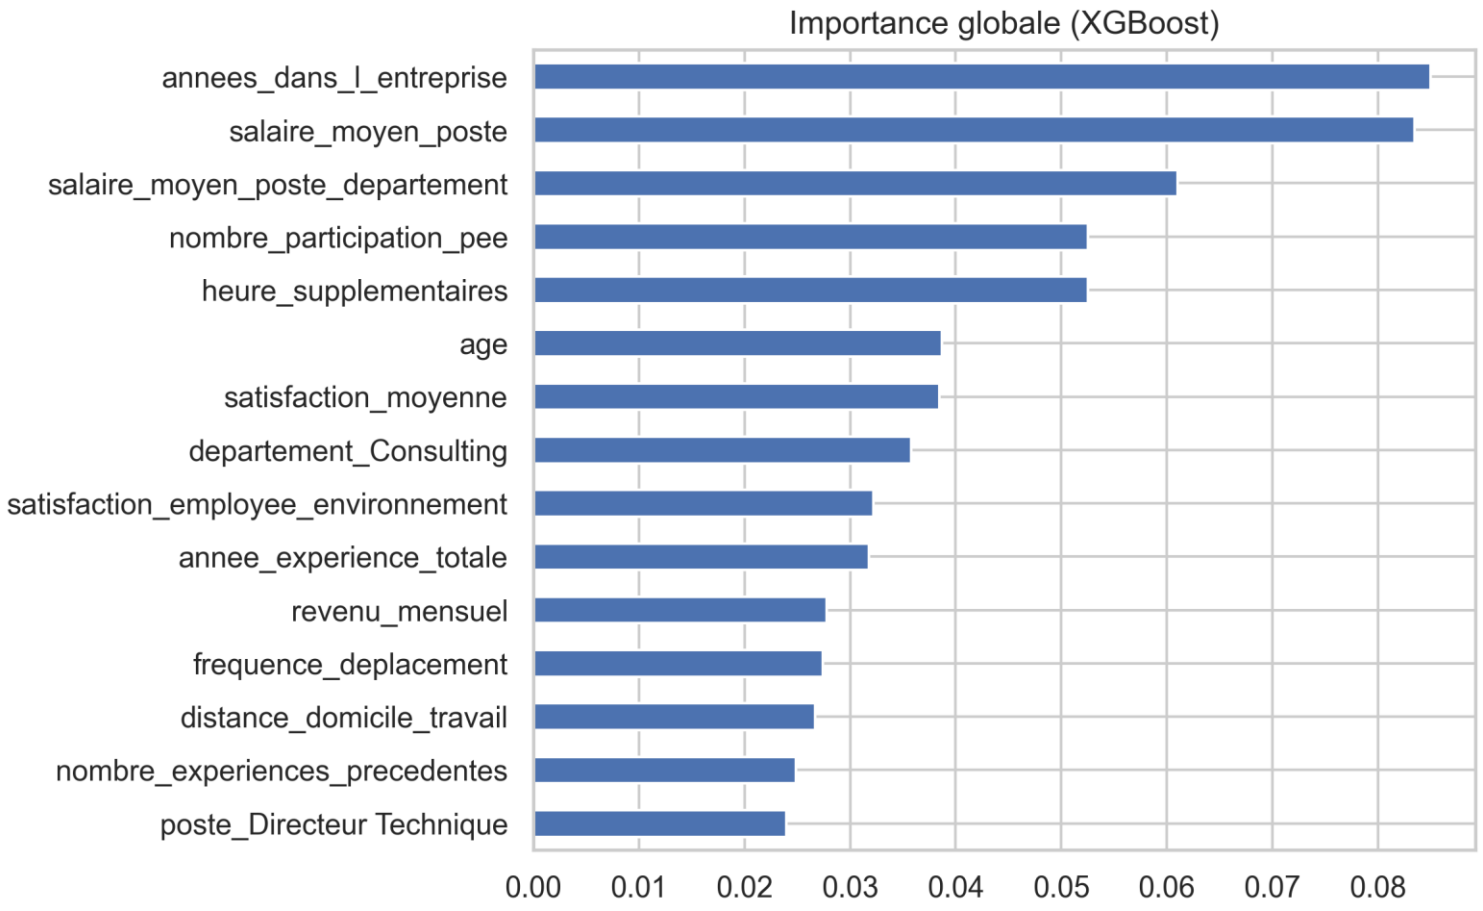

Variables dominantes :

- annees_dans_l_entreprise
- salaire_moyen_poste
- salaire_moyen_poste_departement
- nombre_participation_pee

Modélisation pour la prédiction des départs

Interprétation globale de l’importance des features : SHAP

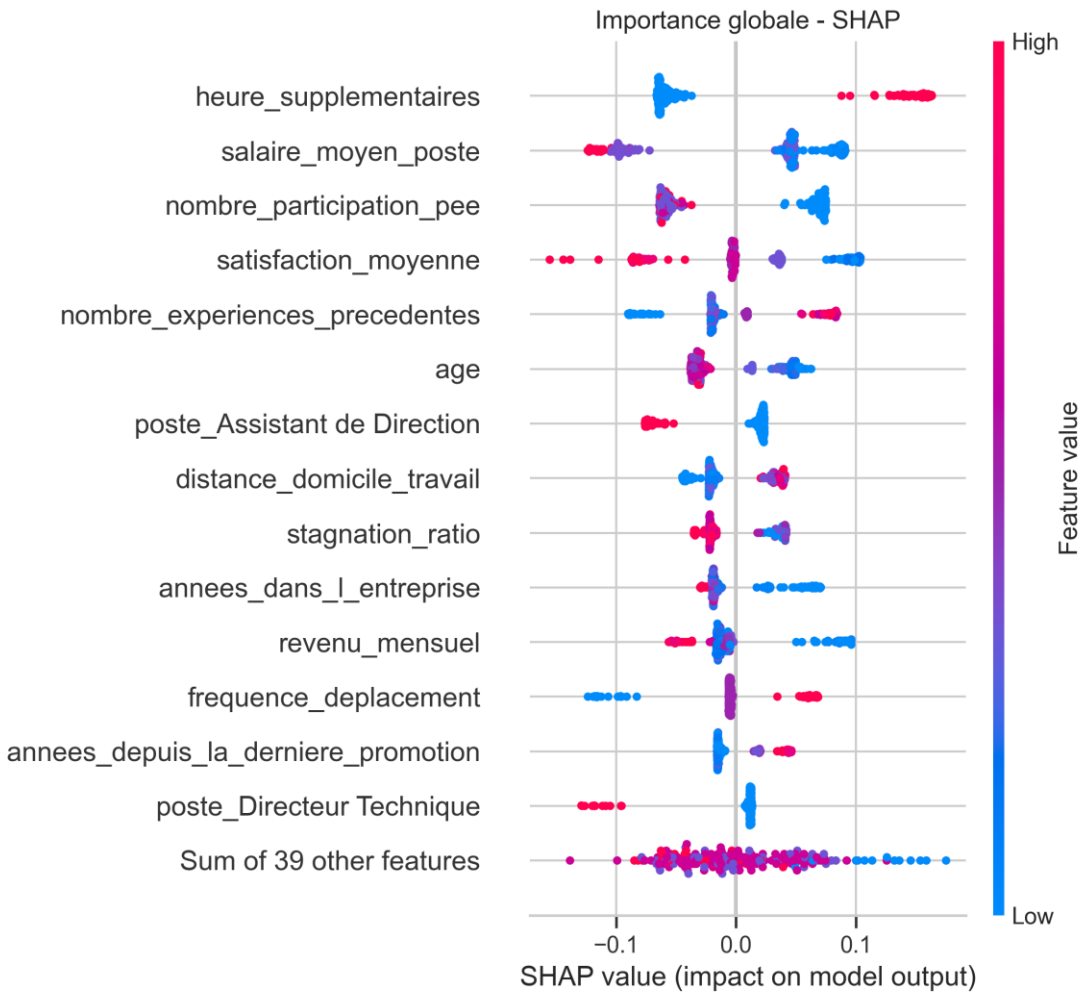

- Un niveau élevé d’heures supplémentaires est associé à un risque accru de démission.
- Une faible satisfaction des employés apparaît comme un facteur clé du départ.
- Un salaire relatif moins compétitif augmente la probabilité de quitter l’entreprise.

Modélisation pour la prédiction des départs

Interprétation locale de l’importance des features : SHAP - waterfall

Classe 0 : employés restant

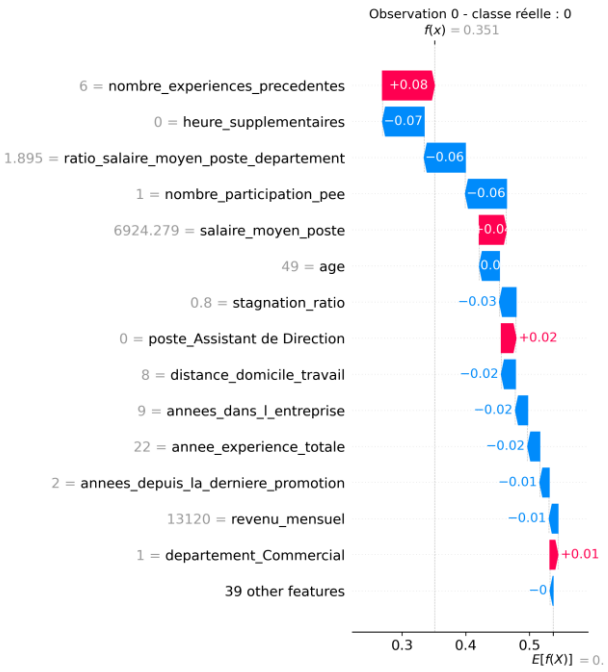

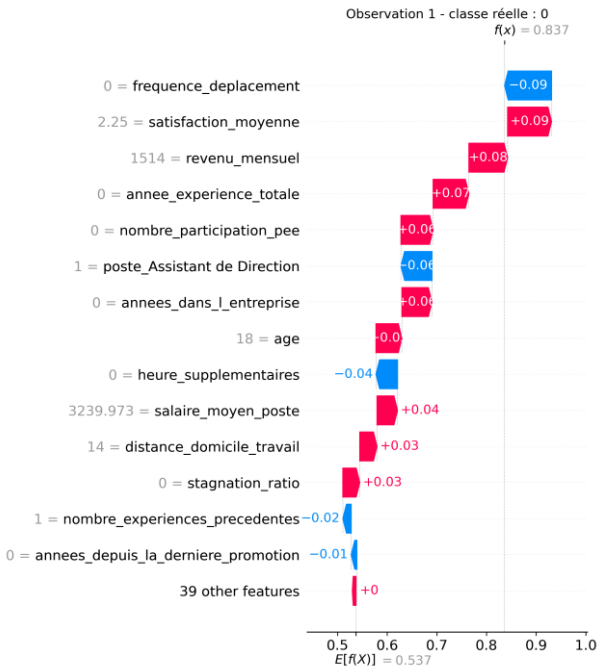

Classe 1 : départs

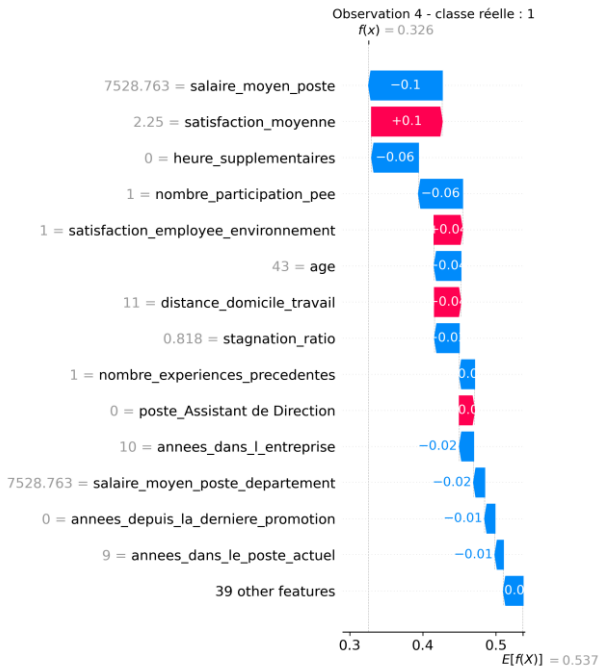

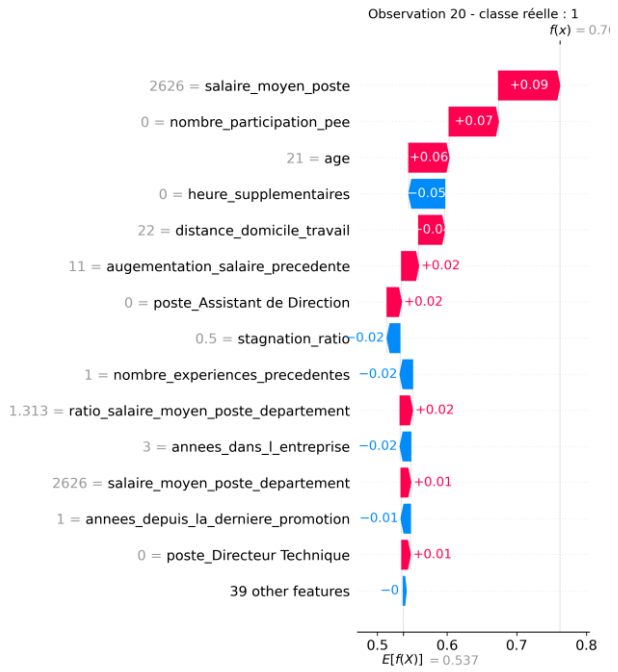

Analyse permettant d’identifier des leviers d’action RH au niveau individuel

Conclusion et perspectives

Conclusion

- Développement d’un modèle de prédiction basé sur **XGBoost optimisé**
- Amélioration de la détection des départs grâce à **l’optimisation du seuil**
- Identification des **variables clés influençant l’attrition**
- Modélisation permettant **d’anticiper les départs** et d’identifier des leviers d’action RH

Perspectives

- Intégration de nouvelles données RH afin d’**améliorer la précision** du modèle (ex. heures de travail, nombre d’enfant)
- Déploiement d’une **API** d’aide à la décision pour les équipes RH

Merci pour votre attention

Faïza Khelladi

Préparation des données

Feature engineering

- Analyse des relations entre variables existantes et variables dérivées afin d'identifier des interactions utiles pour la prédiction

- Enrichissement de l'information à travers le feature engineering

Analyse des relations non-linéaires potentielles

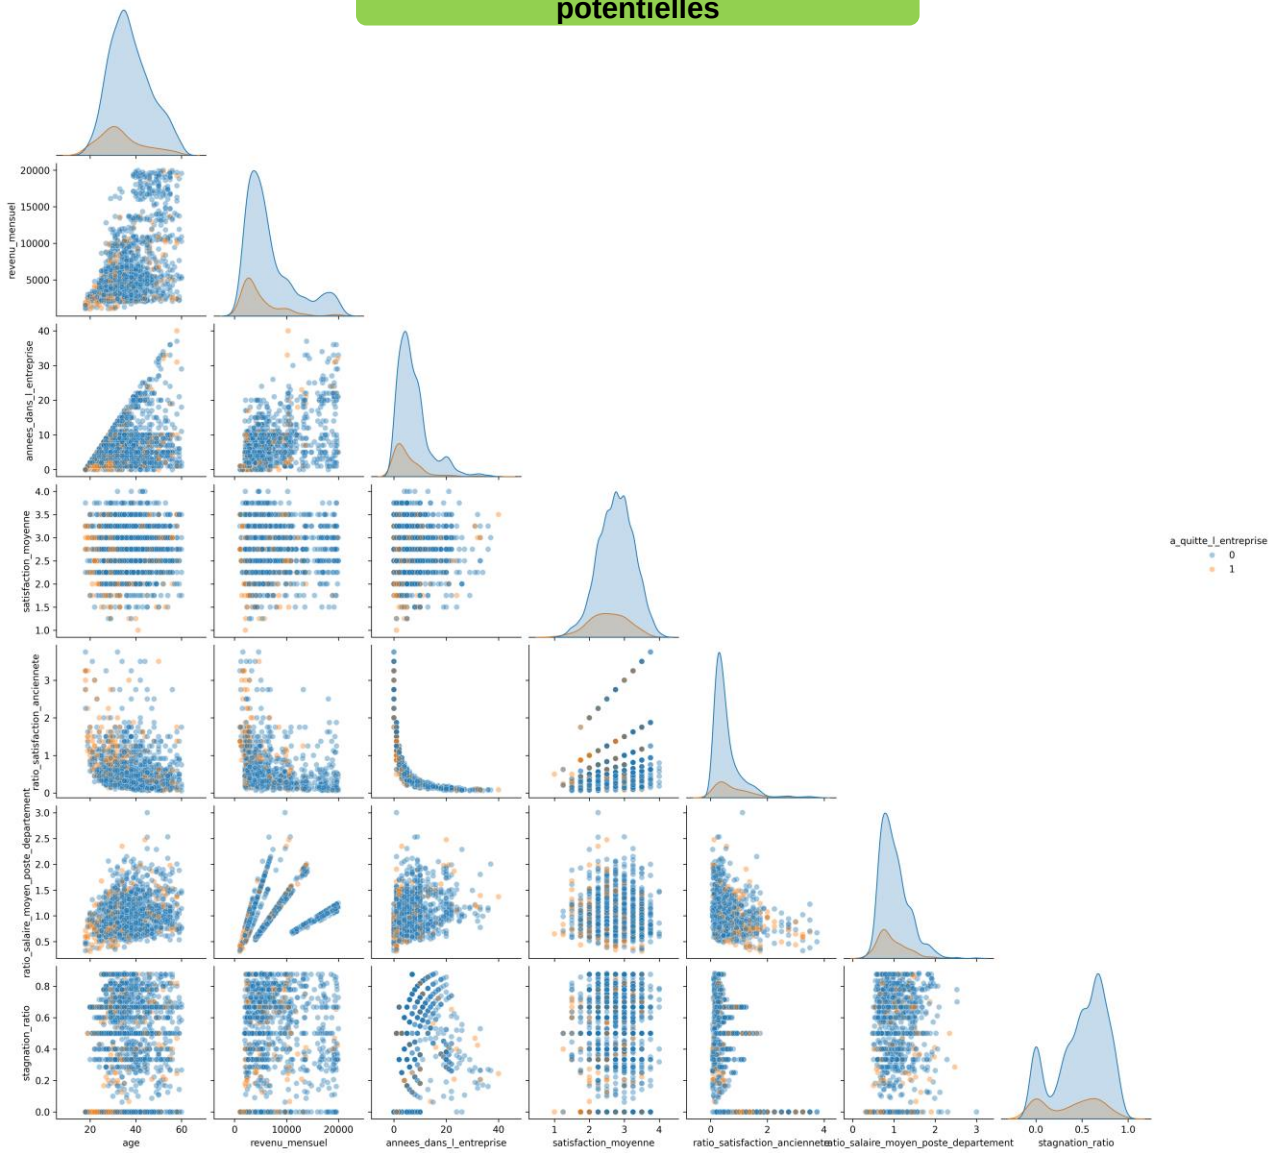

Modélisation pour la prédiction des départs

Interprétation locale de l’importance des features : SHAP - force plots

Classe 0 : employés restant

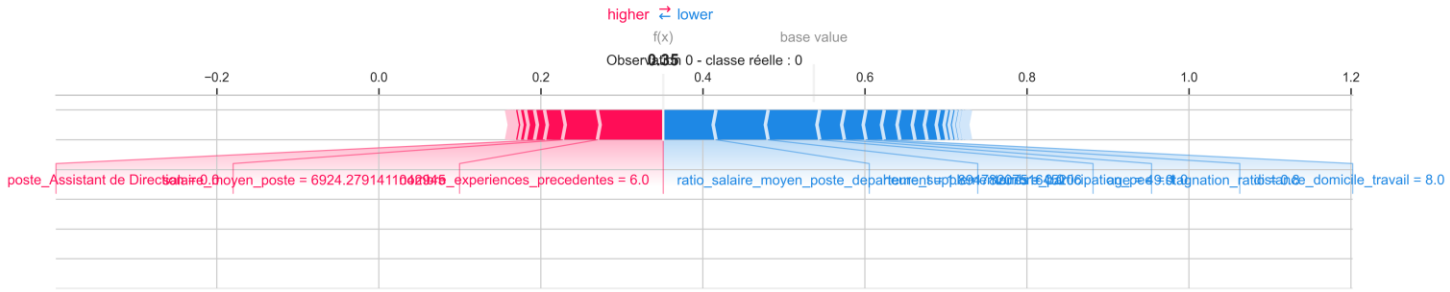

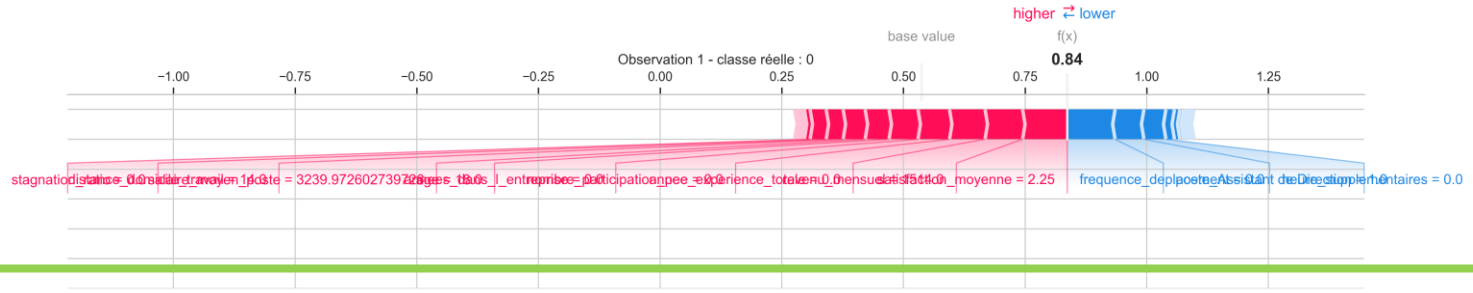

Classe 1 : départs

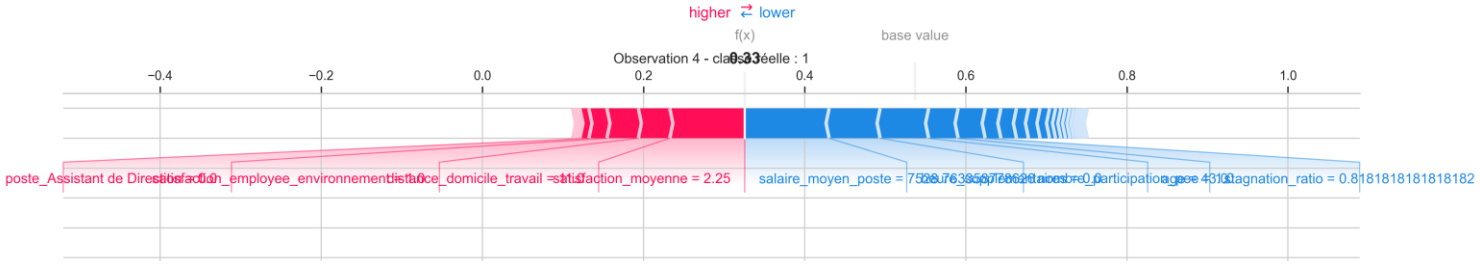

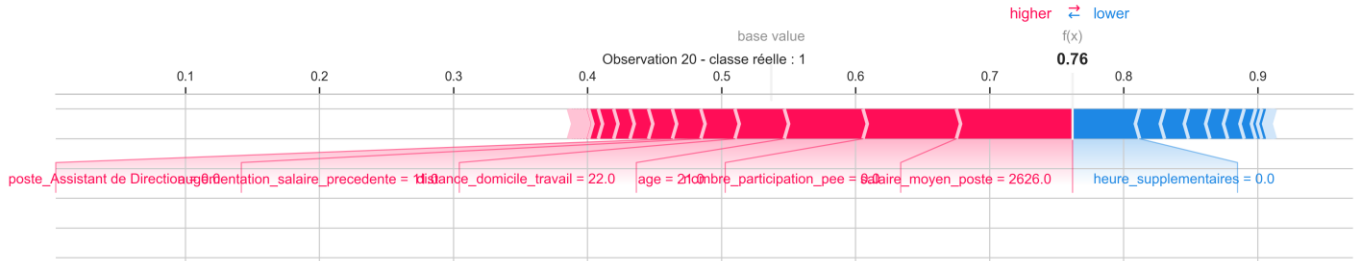

Modélisation pour la prédiction des départs

Interprétation locale de l'importance des features : SHAP - force plots

Classe 0 : employés restant

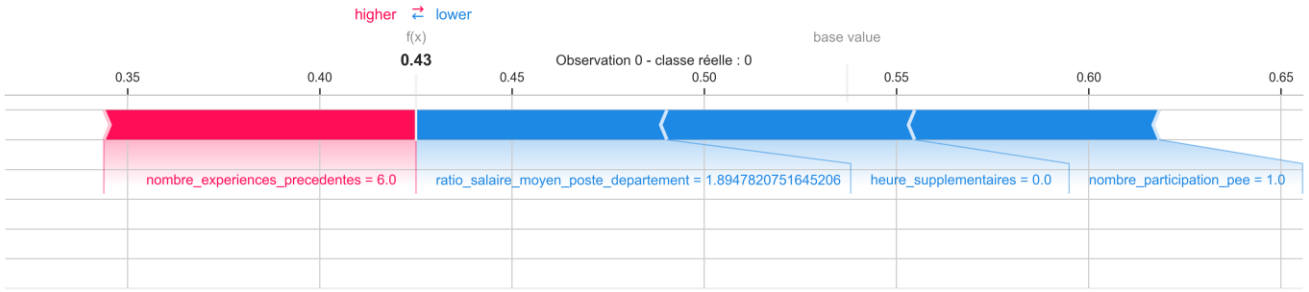

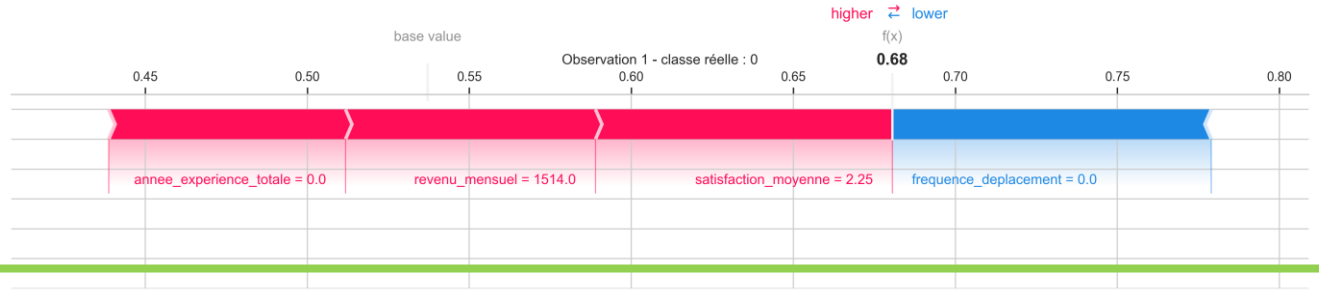

Classe 1 : départs

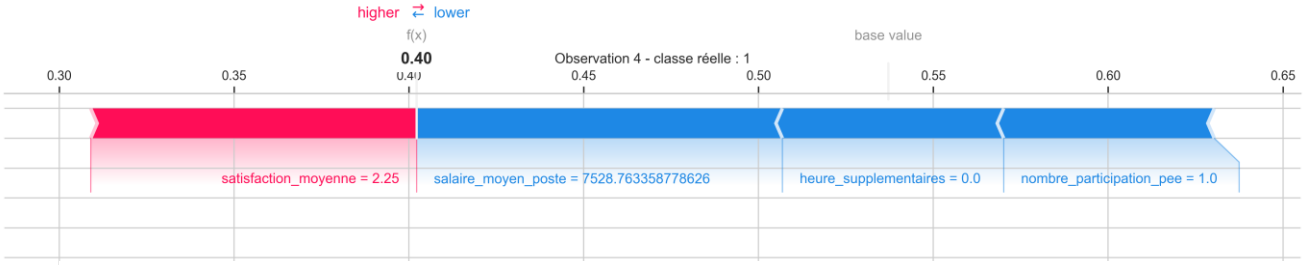

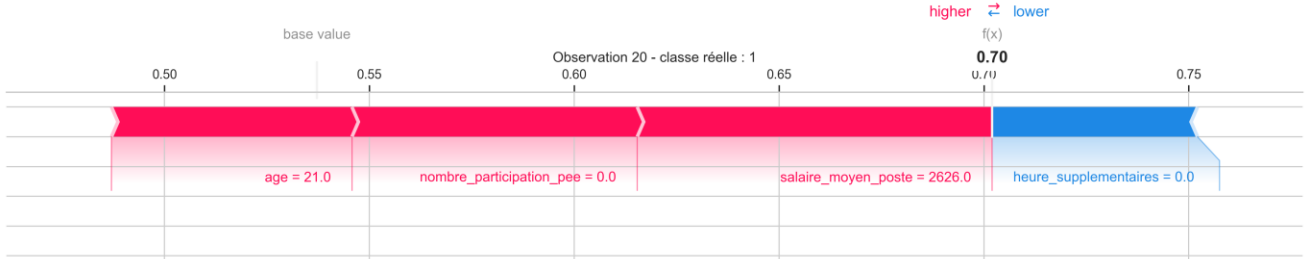

Modélisation pour la prédiction des départs

Interprétation locale de l’importance des features : employés à risque

	nombre_experiences_precedentes	satisfaction_moyenne	nombre_participation_pee	salaire_moyen_poste	heure_supplementaires	prob_depart
602	5	2.75	0	7295.137931	1	0.981055
1389	1	2.50	0	3239.972603	0	0.937273
340	7	3.25	2	7295.137931	0	0.935882
41	1	3.00	1	3237.169884	0	0.910380
403	1	2.25	1	6924.279141	0	0.896460
911	1	3.50	0	2626.000000	1	0.894709
929	1	3.25	1	3237.169884	1	0.886993
700	4	2.75	0	3239.972603	0	0.874963
522	3	3.00	0	3239.972603	0	0.873473
846	2	2.75	1	7295.137931	0	0.868159

Identification des employés présentant la plus forte probabilité de départ afin d’anticiper les actions de rétention